

Spider Book in Python

华聪

前言

总觉得自己不是一个会说话的人，偏偏自己又有很多话要说，那就写下来吧！

——华聪

0.1 更新说明

由于时间有限，不可能一下就把整本书写完。所以，就放出这么一个栏目，每次把更新的内容和时间都列出来。

排版可能有点乱，敬请谅解，可以使用超链接，鼠标双击。

表 1: 更新说明

时间	章节	内容
2018-11-25 14:00	1、2	Python、IDE 和 Python 简介
2018-11-29 14:00	3	Python 基本语法
2018-12-16 11:00	4-5	爬虫基础知识、获取古剑奇谭某帖子的楼层数
2019-01-01 10:30	6	charles 和 beautiful soup4 的简单使用

每次更新，可能会对原来的内容进行小幅修改，但是不一一列举了。

由于标点的关系，pdf 上代码未必能跑，原代码统一放在 github 上https://github.com/hc9701/spider_book/tree/master/code。

0.2 写在前面

写这本书，一方面，是想教会读者如何用 Python 简单地写一个入门级别的爬虫，另一方面，是想对自己学过的知识做个总结，也希望自己能够温故而知新，学到一些新的知识。鉴于笔者的水平，本书中难免会有些错误，希望能通过自己动手实践来发现他们，而不是一味地相信他们。

这本书，面向有一定其它面向对象语言（比如 Java）编程基础，以及有一定前端基础的同学。限于篇幅，书中讲述，以方法为主，不会详细地讲述库怎么用，最多只会介绍有哪些可用的库或者框架。鉴于笔者的水平，本书中难免会有些错误，希望能通过自己动手实践来发现它们，而不是一味地相信它们。

配合百度食用风味更佳哦。

目录

前言	i
0.1 更新说明	i
0.2 写在前面	i
1 Python 及其编辑工具的下载安装	1
1.1 Python	1
1.2 编辑工具	1
1.2.1 Pycharm	2
1.2.2 Spyder	2
2 Python 概述	3
2.1 Python 的自白	3
3 Python 语法基础	9
3.1 Python 代码示例	9
3.2 模块	11
3.2.1 函数	12
3.2.2 类	13
3.3 常用内置数据结构	14
3.3.1 字符串	14
3.3.2 字节	15
3.3.3 列表	15
3.3.4 元组	17
3.3.5 字典	17
3.3.6 集合	18
3.4 流程控制	19

3.4.1	选择	19
3.4.2	循环	20
3.4.3	异常处理	21
3.5	其它特性	21
4	爬虫基础	25
4.1	爬虫流程	26
4.2	用到的知识	26
5	项目一：——纪念你的《古剑奇谭三》游戏瞬间！盖楼晒图赢 GTX1080TI 显卡！	27
5.1	获取总楼层数	28
5.2	需要改进的地方	30
6	考前小作弊——写爬虫刷 acm 题	33
6.1	模拟登录	33
6.2	查看做过的题目	37
6.3	获取代码	38
6.4	提交代码	40

Chapter 1

Python 及其编辑工具的下载安装

工欲善其事，必先利其器。

——《论语·卫灵公》

1.1 Python

Python 的安装有两种选择。

第一，可以去 Python 的官网^[1]下载，值得一提的是，Python 有两类主流版本——2.7 和 3.x (x 表示某个数字)。由于 3.x 的版本已经发行好多年了，而且 2.7 版本有好多第三方的库不支持，所以推荐去下载较新的版本。下载符合自己操作系统的版本。另外需要特别注意，3.x 和 2.7 的语法互不兼容。

第二，可以去 Anaconda 的官网^[2]下载 python 的发行版 Anaconda。Anaconda 是 Python 一个较常用的发行版，里面包括很多科学计算的库。之后要用到的一些库，比如 lxml，Anaconda 已经自带了。再比如一个比较好用的框架 Scrapy，用 Anaconda 的包管理器只需一行命令就可安装，如果用 Python 自带的包管理器 pip，会比较麻烦。下载符合自己操作系统的版本。下载完之后，还需要修改一下源^[3]，因为默认的源是国外的，下载包比较慢。另外，Anaconda 还包括一些好用的工具，比如 Spider、jupyter notebook、Ipython 等。这里强烈建议下载 Anaconda。

无论选哪一种，请参考网上的安装教程，完成 Python 的安装。包括环境变量的配置。否则，你将通过绝对路径使用访问 Python，而不是在终端里直接输入 Python 来使用它。

1.2 编辑工具

Python 的编辑工具很多，小到 Windows 的记事本、notepad++ 等，Linux 的 vim、emacs 等，大到“重剑无锋，大巧不工”的 Pycharm，Spyder 之类的集成开发环境 (Integrated Development Environment, IDE)。可以根据自己的自己的喜好，以及需求，以及收费情况来决定。

^[1]Python 官网: <https://www.python.org>

^[2]Anaconda 官网: <https://www.anaconda.com>

^[3]修改源的教程: <https://jingyan.baidu.com/article/1876c8527be1c3890a137645.html>

当然，对于新人，还是稍微介绍一下两款 IDE——Pycharm 和 Spyder。

1.2.1 Pycharm

用过 JetBrains 家 IDE 的家伙们都知道它们家的 IDE 有多好用，补全，重构等。Pycharm 分免费的社区版 (community) 和收费的专业版 (professional)，区别在于后者对众多常用的 Python web 框架提供了良好的支持，以及对 html, js, 和 css 等 web 相关文件的支持（写爬虫主要是语法高亮，还有数据库可能比较有用）。

当然 Pycharm 也有它的缺点，打开时，会索引很久（找包的路径，方便补全），尤其是电脑比较差的，此时 cpu 占用也很高。另外，Pycharm 调试没有 Spyder 方便。

1.2.2 Spyder

优点，打开速度比 Pycharm 快。调试方便，类似于 MATLAB，可以直接查看变量的数值和类型，运行完后也存在。缺点就是，补全与 Pycharm 无法媲美。

本章小结

本章简单介绍了 Python 和其编辑工具，由于工具很多，没有一一介绍，仅介绍了最好用的两款，对安装还有不懂的同学可以百度一下哦

Chapter 2

Python 概述

千里之行, 始于足下。

——《老子》

2.1 Python 的自白

大家好, 我叫 Python, 我是一个面向对象的语言, 和大家特别好相处, 大家都亲切地叫我 PY。
图 2.1是我的自拍。



图 2.1: Python

帅吧? (读者: dei!) hhhhhhhhhh 我也是这么认为的, 嘻嘻。

emmm... 要凉, 一紧 (Gao) 张 (Xing) 我都忘记要说什么了。且容我看一下台词! 唉, 台词呢? 找到啦! 铛铛铛铛! 图 2.2闪亮登场!

有点难懂对吧? 我来“解释”一下吧。

```
hc@hc-Lenovo-B50-45:~/Documents/spider book$ python
Python 3.7.0 (default, Jun 28 2018, 13:15:42)
[GCC 7.2.0] :: Anaconda, Inc. on linux
Type "help", "copyright", "credits" or "license" for more information.
>>> import this
The Zen of Python, by Tim Peters

Beautiful is better than ugly.
Explicit is better than implicit.
Simple is better than complex.
Complex is better than complicated.
Flat is better than nested.
Sparse is better than dense.
Readability counts.
Special cases aren't special enough to break the rules.
Although practicality beats purity.
Errors should never pass silently.
Unless explicitly silenced.
In the face of ambiguity, refuse the temptation to guess.
There should be one-- and preferably only one --obvious way to do it.
Although that way may not be obvious at first unless you're Dutch.
Now is better than never.
Although never is often better than *right* now.
If the implementation is hard to explain, it's a bad idea.
If the implementation is easy to explain, it may be a good idea.
Namespaces are one honking great idea -- let's do more of those!
>>> █
```

图 2.2: Zen Of Python

友情提醒

关于 The zen of Python，网上有很多解释，仅供参考。一千个 Pythoner 就有一千零一个对 The zen of Python 解释，（还有一个是译文/原文），每个人，相同的人不同的时间，使用不同的 Python 版本，对 The zen of Python 可能有不同的理解，<https://blog.csdn.net/gzlaiyonghao/article/details/2151918> 这个博客里有译文。下面仅介绍其中几点个人理解。

我一个很明显的特点就是代码美观，不像 Java、C、C++ 等语言，通过丑陋的花括号来规定作用域，我采用了缩进（通常是 4 个空格）来规定作用域的范围，因此看上去十分美观。

我的代码十分简洁明了，没有多余的分号。一般能用一句话实现功能的，就不会用一个循环去实现（这样循环就多了，代码的层次、逻辑，就不再那么清晰）。比如，我会用列表（集合、字典）表达式来代替循环。再比如，我有垃圾回收机制，不用的东西，不用自行 free^[1]。

```
# list comprehension l = [x**2 for x in range(1,10)]

# print print(l)
```

^[1]这方面博客很多，但是初学者不需要钻太深，只要知道有垃圾回收即可

```
# for loop l=[] for x in range(1,10): l.append(x**2)

# print print(l)
```

代码清单 2-1.py

友情提醒

这章里暂时不用完全理解代码的意思! 但是如果你有精力, 理解代码对你自己日后写 Python 代码也有好处

可以从图 2.3 看出代码的功能是一样的, 把所有的 1-9 的整数的平方的列表输出到控制台。另外, 还可以看出, Python 虽然是一门面向对象的语言 (如 Java, c++), 但是也支持面向过程 (如 C)。因此, 在编程的时候是很自由的。你不用编写主类, 再编写一个主方法, 你甚至不用写一个主函数, 只要你编写一段能被 Python 解释器 (就是图 2.3 中敲的 python, 类似于 C 里面的 gcc 和 Java 里的 javac) “解释” 的代码, 就能得到结果——或者正确, 或者抛出异常。

```
hc@hc-Lenovo-B50-45:~/Documents/spider book/code$ python 2-1.py
[1, 4, 9, 16, 25, 36, 49, 64, 81]
[1, 4, 9, 16, 25, 36, 49, 64, 81]
```

图 2.3: 2-1.py 运行结果

友情提醒

在代码量大或者需要团队协作的时候, 还是建议写上主函数, 主函数怎么写优雅, 会在下章讲述

这里还要“解释”一下刚才为什么要反复特别强调“解释”这个词。和 C、Java 等编译型语言不一样, 我——Python 不需要编译, 而是由 Python 解释器, 一步一步解释运行。这样子, 以牺牲少许性能为代价, 节约了漫长的编译时间 (如果你的电脑不是很好, 你又编译过大型的项目或者软件, 你就知道编译有多么痛苦, Linux 有些发行版比如 Gentoo 等就是编译安装的, 特别慢, 编译一个 gcc, 要好几个小时。而且编译语言, 常常编译了好久没出错, 到运行的时候再报错, 然后又要 debug, 又要再 compile 一次, 很花时间), 所以总得来说, 我——Python, 还是挺节约时间的。另外, 由于解释器的交互作用 (输入一行 Python 代码, 返回一个结果), 我经常被写这本书的家伙当作计算器用, 无论是进制转换, 还是快速幂, 还是矩阵乘法, 抑或是简单的加减乘除, 都有极其简单的调用方法, windows 自带的 calc 里有的, 我都有, calc 里没有的, 我也基本都有, 哪怕真的没有, 我也可以造轮子般造出来。

说完了我的主要优点, 再说一下我的其它特点。

首先, 我很慢, 这主要归功于我是一门解释型的语言。也许有人不明白, 为什么“解释”就慢^[2]。因为, 一个智能化的编译器可以预测并针对重复和不需要的操作进行优化。这也会提升程序执行的速度。

^[2]关于 Python 慢的原因, 感兴趣的同学可以参考这篇博客《为什么说 python 很慢》<https://www.jianshu.com/p/3fa56d9f58cb>。本书不会一一解释, 仅挑选其中和语言特性有关的进行简单的讲解

第二，我很慢，因为我是动态性语言不是静态性语言，我在声明 `l` 是个 `list` 的时候，不像 `java` 一样 `List<String> l = new ArrayList<String>()`。而是 `l=[]`。也就是说，解释器在解释的时候，不知道 `l` 是什么类型，只知道 `l` 有没有定义过，只有在运行的时候判断这个变量的类型，以及是否有对应的方法。具体见图 2.4。这个动态性的特点，让程序员在编程的时候可以少写很多代码，但是如果程序员犯迷糊，就会帮倒忙（动态一时爽，调试火葬场），比如字符串和整数（甚至小数）后面都可以接 `%` 运算符，但是前者表示用数据来进行格式化，代替 `%d`，`%s` 等占位符，后者是表示取模运算。^[3] 可以利用 `type` 类进行判断。

```
hc@hc-Lenovo-B50-45:~/Documents/spider book/code$ python
Python 3.7.0 (default, Jun 28 2018, 13:15:42)
[GCC 7.2.0] :: Anaconda, Inc. on linux
Type "help", "copyright", "credits" or "license" for more information.
>>> l.append(1)
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'l' is not defined
>>> l=[]
>>> l
[]
>>> l.append(1)
>>> type(l)
<class 'list'>
>>> l=' '
>>> l.append(1)
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
AttributeError: 'str' object has no attribute 'append'
>>> type(l) is str
True
>>>
```

图 2.4: python 动态类型

第三，我很慢，因为我支持多线程，但是支持得很不好，通俗地讲，叫鸡肋，^[4]不能充分地利用 `cpu`（开多个进程除外）。当然写爬虫嘛，没有太大影响，因为爬虫主要是 `IO` 密集型的，计算量很少。所以我在进行 `CPU` 密集型的任务的时候，会很慢。换句话说来说，我不适合进行 `CPU` 密集型的任务。你可能要反驳我说：“深度学习了解一下？”。那么，我要给你介绍一下我的绰号——“胶水语言”^[5]。我一般来完成业务流程，而需要性能的核心模块（比如 `numpy` 之类和科学计算有关的库）由我的兄弟 `C/C++` 这样的语言来写。如果你快，那很 `OK`，但是如果你不快还不会抱大腿，那么非常 `Sorry`，你是比不过我的。

Last but not the least，这回总算和慢不搭边了。我是强类型的语言！我是强类型的语言！我是强类型的语言！重要的话说三遍！以后如果和别人介绍我，你可以说我是动态类型的，但是如果你和别人说我是弱类型的，对不起，咱们不认识！`1+“1”=2`，这叫弱类型（某一个变量被定义类型，该变量可以根据环境变化自动进行转换，不需要经过显性强制转换。）；`1+“1”=` 报错，这叫强类型（如果不经过强制转换，则它永远就是该数据类型了）。虽然稍微麻烦了一点，但是可以避免很多 `Bug`（`Php`：为什么每次躺枪的都是我）。

^[3] 这点与 `c` 不同，主要体现在负数上，可以参考博客<https://blog.csdn.net/SharonLu1216/article/details/76774829>

^[4] 关于 `Python` 为什么多线程鸡肋，推荐看<https://www.zhihu.com/question/23474039>里高赞的回答，虽然有点难

^[5] 关于胶水语言，可以参考知乎<https://www.zhihu.com/question/21626095>

本章小结

本章介绍了一些 Python 的性质和特点，虽然内容有点枯燥，但是作者用幽默的语言（不要脸）进行了说明，对以后的学习会有点帮助。下章开始，要介绍 Python 的基本语法了。

Chapter 3

Python 语法基础

Life is short, you need Python.

——Bruce Eckel

3.1 Python 代码示例

友情提醒

本章开始，将广泛用到终端，Linux 和 windows 都行，但笔者推荐 Linux，因为后期用到 docker，对一般人来说，Linux 更方便，以下命令，如无特别指明，皆指 Linux 命令

```
import requests req = requests.get('http://www.xicidaili.com/nn/')
print('content',req.content,sep=': ') print(type(req.content))
print('-'*10,'end','-'*10,end='来个换行吧')
```

代码清单 3-1.py

```
hc@hc-Lenovo-B50-45:~/Documents/spider book/code$ vim 3-1.py
hc@hc-Lenovo-B50-45:~/Documents/spider book/code$ python 3-1.py
content: b'<html>\r\n<head><title>503 Service Temporarily Unavailable</title></h
ead>\r\n<body bgcolor="white">\r\n<center><h1>503 Service Temporarily Unavailabl
e</h1></center>\r\n<hr><center>nginx/1.1.19</center>\r\n</body>\r\n</html>\r\n'
<class 'bytes'>
----- end -----来个换行吧hc@hc-Lenovo-B50-45:~/Documents/spider book/c
ode$
```

图 3.1: 代码示例

结果如图 3.1所示。

Excuse me? 不是说好了这章讲语法的吗？一上来就扔了个代码和结果，让我们自学？

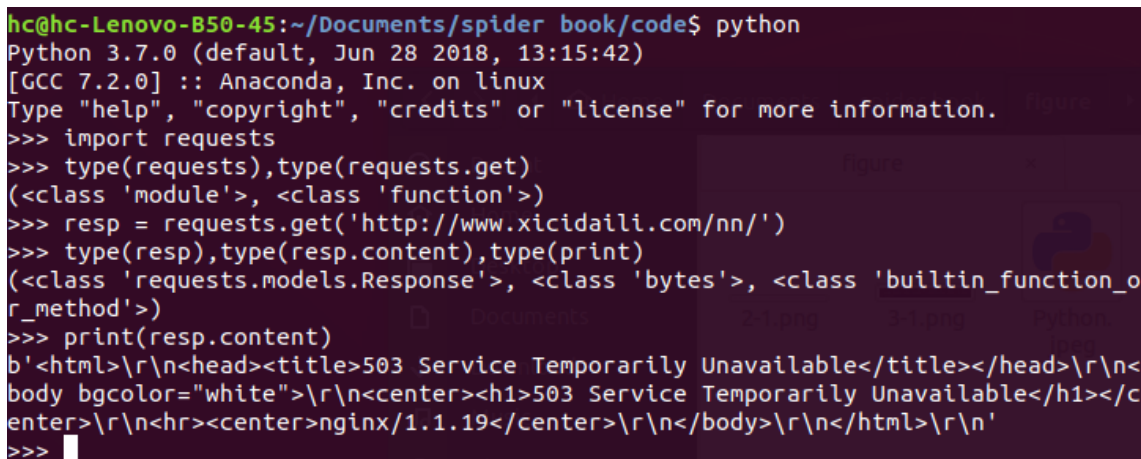
非也非也！首先，我是要告诉你怎么运行 python 源代码（推荐命名为 *.py）——python filename。如果你的目的是“系统地”学习语法，那么恭喜你，来错地方了。菜鸟教程^[1]和廖雪峰的教程^[2]讲得比我更好，前者适合真菜鸟，后者适合假菜鸟（不会 Python，但是其它语言基础比较好），但是后者质量不错，比前者更好，能学到更多知识。

友情提醒

个人觉得，直接讲语法，会有一些不懂的，或者因为厌倦而放弃，或者看似学会了，但不知道怎么用。给出代码，可以引起好奇心，哇，Python 原来还有这种丧心病狂的功能！可以在给出的代码的基础上进行修改，写少量自己不会写的代码，避免重复劳动，做做实验，加深印象。

接下来，我们打开终端（cmd），确保你已经配置好 Python（包括 pip）的环境变量，以及 requests 库（Linux 用户可以通过 `pip list | grep requests` 命令来确认是否安装 requests 库，或者输入 `python` 回车，`import requests` 回车）。如果没有装 requests 库，在终端输入：`pip install requests`；如果没有配置好环境变量，那么，请百度相关教程。

之后，输入 Python，按照图 3.2，输入这些内容。



```
hc@hc-Lenovo-B50-45:~/Documents/spider book/code$ python
Python 3.7.0 (default, Jun 28 2018, 13:15:42)
[GCC 7.2.0] :: Anaconda, Inc. on linux
Type "help", "copyright", "credits" or "license" for more information.
>>> import requests
>>> type(requests),type(requests.get)
(<class 'module'>, <class 'function'>)
>>> resp = requests.get('http://www.xicidaili.com/nn/')
>>> type(resp),type(resp.content),type(print)
(<class 'requests.models.Response'>, <class 'bytes'>, <class 'builtin_function_o
r_method'>)
>>> print(resp.content)
b'<html>\r\n<head><title>503 Service Temporarily Unavailable</title></head>\r\n<
body bgcolor="white">\r\n<center><h1>503 Service Temporarily Unavailable</h1></c
enter>\r\n<hr><center>nginx/1.1.19</center>\r\n</body>\r\n</html>\r\n'
>>>
```

图 3.2: type 所有变量

稍微总结一下，通过这些 `type`，我们可以看到 Python 做了很多事：导入（`import`）模块（`requests`）。调用模块（`requests`）里面的函数（`get`）向 <http://www.xicidaili.com/nn/> 这个网站发送一个 `get` 请求，以及调用 Python 内置的函数（`print`），将一个 `bytes` 类型的对象（响应的正文部分）输出到控制台。然后还可以知道这些类名也好，函数名也罢，都是某个类的对象，因此，一般的对象的操作（比如赋值）对函数名和类名等，都是可以使用的。也就是说，我们在给自己的对象起名字的时候，最好不要使用已经有的类的名字，否则会覆盖原有的功能，除非你真的希望这样做。

有了这些基础的认识，我们先来了解模块 `requests`。

^[1]Python3 教程 <http://www.runoob.com/python3/python3-basic-syntax.html>

^[2]Python 教程 - 廖雪峰的官方网站 <https://www.liaoxuefeng.com/wiki/0014316089557264a6b348958f449949df42a6d3a2e542c000>

3.2 模块

小诀窍

学习最好的方法就是模仿，尤其是有点基础的人，找个库的代码看看，可以学到不少知识。

如图 3.3 在终端中输入 `find` 你的 `anaconda` 安装目录 (我是 `/anaconda3`) `-name requests`, 然后, `cd` 进入其中一个文件夹。再执行 `ls` 命令。

```
hc@hc-Lenovo-B50-45:~/Documents/spider book$ find ~/anaconda3/ -name requests
/home/hc/anaconda3/pkgs/requests-2.19.1-py37_0/lib/python3.7/site-packages/requests
/home/hc/anaconda3/pkgs/pip-10.0.1-py37_0/lib/python3.7/site-packages/pip/_vendor/requests
/home/hc/anaconda3/pkgs/pip-9.0.1-py36_1/lib/python3.6/site-packages/pip/_vendor/requests
/home/hc/anaconda3/pkgs/pip-18.1-py36_0/lib/python3.6/site-packages/pip/_vendor/requests
/home/hc/anaconda3/lib/python3.7/site-packages/requests
/home/hc/anaconda3/lib/python3.7/site-packages/pip/_vendor/requests
hc@hc-Lenovo-B50-45:~/Documents/spider book$ cd /home/hc/anaconda3/pkgs/requests-2.19.1-py37_0/lib/python3.7/site-packages/requests
hc@hc-Lenovo-B50-45:~/anaconda3/pkgs/requests-2.19.1-py37_0/lib/python3.7/site-packages/requests$ ls
adapters.py  compat.py      hooks.py       packages.py    structures.py
api.py       cookies.py     __init__.py    __pycache__    utils.py
auth.py      exceptions.py  _internal_utils.py  sessions.py    __version__.py
certs.py     help.py        models.py      status_codes.py
```

图 3.3: 寻找 `requests` 库的路径

在这些文件中,有一个 `__init__.py`,准确地说,每个 Python 的包里面都有一个叫 `__init__.py` 的文件。这是 Python 包和一般文件夹的本质区别,如果 `__init__.py` 不存在,这个目录就仅仅是一个目录,而不是一个包,它和里面的模块和嵌套包(比如 `numpy.linalg` 这个 `numpy` 包的子包)就不能被导入。因此,我们如果有自己写一个包的时候,千万不要把 `__init__.py` 的文件给删除了,宁可放一个空的 `__init__.py` 的文件 (IDE 一般会为我们创建一个 `__init__.py`,不用我们自行创建)。

接下来,我们可以看一下 `requests` 包的 `__init__.py` 文件,看一下怎么编写 `__init__.py` 文件,以及涉及的一些 Python 语法。

用编辑器 (Linux 下的 `gedit`, `vim/vi`, `emacs`, `nano` 等, windows 下的 `notepad++`, `notepad` 等或者一些跨平台的如 `sublime text`) 打开 `__init__.py` 文件,或者用 `spider`, `Pycharm` 的 IDE 的代码跳转等功能,或者去 `github` 或 `pypi` 上搜索 `requests`^[3] 查看 `__init__.py` 的代码。

友情提醒

^[3] 这种方法不一定能找到所有的库。requests github: https://github.com/requests/requests/blob/master/requests/__init__.py pypi: <https://pypi.org/project/requests/>

PyPI(Python Package Index) 是 python 官方的第三方库的仓库, 所有人都可以下载第三方库或上传自己开发的库到 PyPI。PyPI 推荐使用 pip 包管理器来下载第三方库。

100 多行的代码, 看下它做了怎样的事。(版本不同, 代码可能有一些不同)。

第一行, `# -*- coding: utf-8 -*-` 声明编码方式为 utf-8。

第 3-6 行, `#` 开头, 用于注释, 会被解释器读取 (如声明编码), 但不会被执行。这里画了一个 Requests。(丑)

后面许多行被 2 对 3 个双引号包括, 表示多行字符串, 关于字符串, 在小小节 3.3.1 节会讲述。讲述了 requests 库的基本用法。

第 43 行到 46 行导入了一些模块。到这里, 已经出现了两种导入模块的方法。那么这里就总结一下, 顺便剧透一下剩下的用法, 以 requests 库举例。

- 1) import 模块。调用: 该模块. 对象 (如果是这里的对象是广义的对象, 通过这段时间的学习, 相信你已经能够意识到, 模块名, 函数名, 类名, 变量, 这些其实都是一个对象的引用) 举例: `import requests` 然后 `r = requests.get('http://www.baidu.com')`
- 2) from 模块 import 对象。调用: 该对象。举例: `from requests import get` 然后 `get('http://www.baidu.com')`
- 3) import 模块 as 别名。调用: 别名. 对象, 不能用该模块名. 对象访问。(模块名比较丑的时候, 比较好用) `import numpy as np` 然后 `a=np.mat([[1,2],[1,3]])`
- 4) 模块可以用相对路径引用, `.` 模块, `..` 模块, 见 46 行, `*` 可以匹配所有对象。

小诀窍

如果你感到没有看懂, 可以在 Python 解释器中输入 `globals()` 函数, 用各种方式导入一个模块, 再输入 `globals()` 函数, 看看有什么区别, 你就明白了

接下来是 2 个 `def` 代码, 我们暂时先不要仔细地看下面的内容, 只要知道这是 2 个函数, 里面用了 `if` 控制流程即可。后面是捕获异常。后面就没啥熟悉的知识了。

代码的结构已经剖析完了, 接下来来聊聊为什么要用模块。

我们写模块的目的是, 让代码模块化, 更容易复用。在这方面做得比较好的, 除了模块, 还有俩, 一个是函数, 一个是类, 而且, 在模块中, 函数和类也是很常见的, 或者是写在模块本身, 或者是写在其它模块被导入。

3.2.1 函数

函数, 在 c 里面见过, 但是, 如果只是 C 里函数的功能, 那么这门语言就不配用 “人生苦短, 我用 Python” 这句广告了。Python 中的函数究竟有什么强大之处?

首先, 由于 Python 是动态类型的, 所以不用声明返回类型, 参数也不用类型。

第二，由于 Python 内置的数据结构元组（tuple）（见小小节 3.3.4），使得 **Python** 可以返回 **0-多个返回值**。

第三，Python 可以给函数提供默认参数，默认参数的存在，使得 Python 函数的调用，千变万化，可以省略默认参数，可以提供不同功能（在函数中加上 if），类似于 Java 中的方法重载，却比它简单得多。不过，无论是函数，还是方法，Python 都不支持重载，因为，函数名或者方法名，本身就是一个对象的引用，如果你定义了两个相同名字的对象，那么后面一个势必会取代前面一个，把它覆盖，你将无法调用前面一个。另外需要注意，有默认值的参数，必须放在无默认值的参数后面。

第四，Python 在调用函数写实参的时候，可以为每个参数添加函数名来增加可读性，也方便程序员编码，因为由于你指定了名字，Python 解释器就可以机智地区分他们，可以少记很多参数的顺序，如 `requests.get(headers={},url='http://www.baidu.com')`（我们可以把它叫做关键字参数，调用实参的时候没有函数名的参数叫位置参数）。关键字参数必须放在位置参数的后面。

小诀窍

关于关键字参数必须放在位置参数的后面这一点，可以参考数学中的排列组合问题——排队，有位置限制的，必须先排，没位置限制的，可以放到他们排好以后再排，在 Python 中，位置参数就是位置有要求的参数

友情提醒

Python 中的函数和方法没有访问权限这一概念，如果你不希望你的方法被其它模块调用，请以 `_` 开头命名函数

友情提醒

对于简短的函数，可用 lambda 表达式代替，`f1=lambda : 'hello world', f2=lambda x,y: print(x+2*y)`

3.2.2 类

和类联系在一起的一个概念，就是面向对象，由于爬虫涉及的面向对象的知识很少，这里就作一个简单的介绍，如有需要，可以查找网上的教程。

类，用 `class` 类名（父类名）：声明。一个类里面存在 0 个或多个方法。方法，可以理解成和类绑定在一起的函数，但是比函数多了一个 `self` 参数，表示函数所属的对象本身。其中有一些魔法方法，开头和结尾都有 2 个 `_`，在特定的时期会调用。比如 `__init__`，在类初始化的时候调用，可以理解成 java 中类的构造方法，还有一些魔法方法，实现它们可以让我们以更简单的方法去调用它们，后面要讲的列表，字典，之所以调用如此方便，就是在编写这些类的时候，实现了其中的一些魔法方法。函数或方法，之所以对那么多种类的对象都适用，因为某些函数在编写的时候，并不是直接处理对象的，而是，调用对象写好的魔法方法，对于魔法方法，我们不需要过多关心，了解它们存在即可。

创建类，用类名（参数）的方式，比如 `a=list((1,2,3))`

另外, Python 没有接口的概念, Python 有多重继承, 但是不常用, 继承其它类, 一个父类基本够用, 调用父类的方法用得不多, 可以用到时百度。

3.3 常用内置数据结构

Python 好用的一个原因, 就是内置了许多好用又常用的数据结构, 比如字符串, 列表, 元组, 字典等, 每种数据结构都有很多丰富的好用的方法。

3.3.1 字符串

字符串 (比如 'Python', "py") 用一对单引号或一对双引号表示, 基本没有区别, 在引号内有双引号时, 推荐用单引号, 在引号内有单引号时, 推荐用双引号, 否则需要转义。

多行字符串用一对 3 引号表示, 用于注释或说明。

字符串里, 有很多常用的方法。如图 3.4 所示。这个内置数据结构将在以后频繁用到。

```
>>> str1='\nPython ,Jython, Cython,PyPy and ironPython\n'
>>> str1.split()
['Python', ',Jython,', 'Cython,PyPy', 'and', 'ironPython']
>>> str1.split('and')
['\nPython ,Jython, Cython,PyPy ', ' ironPython\n']
>>> str1.strip()
'Python ,Jython, Cython,PyPy and ironPython'
>>> str1.rstrip()
'\nPython ,Jython, Cython,PyPy and ironPython'
>>> str1.lstrip('\nPython')
',Jython, Cython,PyPy and ironPython\n'
>>> ','.join('Python')
'P,y,t,h,o,n'
>>> ','.join(['3','6','0'])
'3,6,0'
>>> ','.join([3,6,0])
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: sequence item 0: expected str instance, int found
>>> str1.count('ython')
4
>>> str1.find('ython')
2
>>> str1.find('java')
-1
>>> str1.upper()
'\nPYTHON ,JYTHON, CYTHON,PYPY AND IRONPYTHON\n'
>>> str1.lower()
'\npython ,jython, cython,pypy and ironpython\n'
>>> str1.count('java')
0
>>> str1.index('java')
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
ValueError: substring not found
```

图 3.4: Python

`strip` 默认去除字符串两侧的中英文空格，制表符 `\t`，换行符 `\r`、`\n` 等，添加参数，可以使指定字符去掉。`l` 表示 left, `r` 表示 right。

`split` 方法指定分隔符对字符串进行分割，甚至还可以指定次数，默认全部分割。

`string` 模块的函数不支持正则表达式，如果想调用正则表达式，请用 `re` 模块。

`join` 用指定参数将参数们连接到一起（参数必须可迭代的字符序列，比如字符列表，字符元组，字符串等）

`replace` 方法返回替换后的对象，但不对参数本身进行修改。

`find` 和 `index` 方法可以检测字符串中是否包含子字符串 `str`，如果指定 `beg`（开始）和 `end`（结束）范围，则检查是否包含在指定范围内，如果包含子字符串返回开始的索引值，否则 `find` 返回 -1, `index` 抛出异常。

`count` 方法返回字符出现的次数。

字符串中的 `\` 表示转义字符，如果在正则表达式或者路径中，需要用到，要用 2 个 `\` 来代替。或者用 `r'\ is a backslash'` 的方式（外面加个 `r` 表示 raw, 里面的 `\` 不转义）。

3.3.2 字节

字节（bytes）既不好用，又不常用，但是在爬虫中又偏偏要用到。

字节用 `b''` 表示。如 `b'<html><body></body></html>'`。这里要掌握它与字符串的互相转换。

字符串转字节，用 `str.encode()` 方法。字节转字符串用 `str.decode()` 方法。可以添加参数，一般为 `'UTF-8'`

3.3.3 列表

这是一类十分常用的，像数组，链表的东西。但是，列表里，可以是任意类型的，可以是任意长度的。

列表用 `[]` 表示, 类名 `list`。

`append` 方法在后面添加指定对象，`extend` 在后面用参数列表延展原列表。

Python 列表索引从 0 开始，支持负索引，即右往左数。

切片是 Python 又一丧心病狂的语法糖。格式为 `l[start:end:step]` 支持正向切、反向切、跳着切、切到底、切一半、边切边改、切了当拷贝。包括 `start` 但不包括 `end`。

友情提醒

关于切片什么时候会改变原值，什么时候不会，请自行思考（考虑一下引用）并实验

切片的强大，使得一些 `list` 的方法不常用了，比如 `reverse` 方法和内置的 `reversed` 函数。

```
>>> l=[1,2,3,4,5]
>>> l.append(6)
>>> l.extend([7,8,9])
>>> l
[1, 2, 3, 4, 5, 6, 7, 8, 9]
>>> l[-1]
9
>>> l[0:4]
[1, 2, 3, 4]
>>> l[0:-1]
[1, 2, 3, 4, 5, 6, 7, 8]
>>> l[0:]
[1, 2, 3, 4, 5, 6, 7, 8, 9]
>>> l[0::3]
[1, 4, 7]
>>> l[3:5]=9,8
>>> l
[1, 2, 3, 9, 8, 6, 7, 8, 9]
>>> a=l[3:5]
>>> a[0]=-1
>>> a
[-1, 8]
>>> l
[1, 2, 3, 9, 8, 6, 7, 8, 9]
>>> reversed(l)
<list_reverseiterator object at 0x7f9bc1f9ca20>
>>> list(reversed(l))
[9, 8, 7, 6, 8, 9, 3, 2, 1]
>>> l
[1, 2, 3, 9, 8, 6, 7, 8, 9]
>>> l.reverse()
>>> l
[9, 8, 7, 6, 8, 9, 3, 2, 1]
>>> l.sort()
>>> l
[1, 2, 3, 6, 7, 8, 8, 9, 9]
```

图 3.5: list

友情提醒

Python 里有很多像 reverse, reversed 这样命名的方法或函数，比如 sort, sorted，性质有所不同。前者改变自身，后者不改变自身，而是返回一个拷贝。

小诀窍

时间久了可能会记反，这里给出一个我的记忆方式，英语中，动词 +ed，是过去分词，常常用来当形容词。因此，sorted 函数返回一个形容词版（有序的）的列表，不改变列表本身。而 sort 是方法，表示一个对象的行为或者动作，这个行为或动作的对象是 self，即列表本身。

友情提醒

`reversed` 方法返回一个生成器, `sorted` 方法返回一个列表。生成器可以生成列表, 但是不会立即生成, 在用 `for` 语句迭代的时候和列表相似, 所以比较节约内存。

3.3.4 元组

元组用 `(1,)` 或 `(1,2,3)` 表示, `()` 可以省略 (如果不会发生歧义, 比如交换变量, 可以省略 `()`, 但是函数参数那里, 就不能省略)

元组和列表十分相似, 所以, 不介绍它的语法了。唯一的区别是, 元组不支持修改。类名为 `tuple`。

元组可以干啥? 函数多值返回, 并行赋值 (交换两个变量可以用 `a,b=b,a`), 可以当字典的键 (这点列表不行)。

3.3.5 字典

字典是 Python 中又一好用的数据结构, 类名 `dict`, 用 `key1:value,key2:value` 表示, 特点是可以直接根据键名获取键值。一方面, 用过其它语言 `map` 数据结构的人, 都知道 `map` 有多好用, 存取有多方便。另一方面, 现在很多网页都是通过 `json` 格式传输数据的, 这意味着爬虫有时需要抓取 `json` 格式的数据。而 `json` 和字典一样, 都是键值对的形式, 这意味着, `json` 和 `dict` 可以方便地转换 (标准库里的 `json.dumps,json.loads,json.load,json.dump`)。有些 NoSQL (比如 `Mongodb`) 也是键值对类型的, 因此, 也可以通过 `dict` 来封装对应的数据。

小诀窍

这里, 又出现了令人混淆的函数名, 可以这样记忆 `dumps,loads` 的 `s` 可以记忆为 `string`, 说明这两个函数是对 `string` 类型操作, 剩下两个是对文件操作。

`dict` 的基本用法可以见图 3.6。

假设字典的名字叫 `d`。

获取键值的方式有 3 种, 一种是 `d[键名]`, 一种是 `d.get(键名)`, 一种是 `d.setdefault(键名, 默认值)`。区别在于, 在不存在键名的时候, 用 `d[键名]` 获取键值会报错, `get` 方法会返回 `None` (类似于 `c` 里的 `NULL` 各 `java` 里的 `null`, 以及一些其它语言中的 `nil`)。 `d.setdefault` 方法会返回默认值并修改字典。

`update` 允许用新的字典去更新旧的字典。如果旧字典没有对应的键, 那么旧字典会增加对应的键名和键值。如果旧字典有对应的键名, 那么新字典会更新对应的键值。如果新字典没有对应的键名, 那么旧字典对应的键值不会被改变。

`d.keys()` 方法获取字典的键名的集合 (`dict_keys`)。之所以叫作集合, 因为, 字典里不会有相同的键值。键名必须是不能修改的对象, 比如元组, 字符串, 数字, 但不能是可以修改的对象。

`d.values()` 方法获取字典里的键值列表 (`dict_values`)。


```

>>> d={'man': 'huacong', 'woman': 'syj'}
>>> d['man']
'huacong'
>>> d['is_couple']
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
KeyError: 'is_couple'
>>> d.get('is_couple')
>>> d.setdefault('is_couple',0) # 单身狗心中永远的痛55555
0
>>> d['is_couple']
0
>>> d
{'man': 'huacong', 'woman': 'syj', 'is_couple': 0}
>>> d.update({'is_couple':1,'have_child':0}) # someday in the future
>>> d
{'man': 'huacong', 'woman': 'syj', 'is_couple': 1, 'have_child': 0}
>>> d.keys()
dict_keys(['man', 'woman', 'is_couple', 'have_child'])
>>> d.values()
dict_values(['huacong', 'syj', 1, 0])
>>> d.items()
dict_items([('man', 'huacong'), ('woman', 'syj'), ('is_couple', 1), ('have_child', 0)])
>>> d1 = dict([('man', 'huacong'), ('woman', 'syj'), ('is_couple', 1), ('have_child', 0)])
>>> d1
{'man': 'huacong', 'woman': 'syj', 'is_couple': 1, 'have_child': 0}
>>> d2=zip([1,2,3],[4,5,6])
>>> d3 = dict(d2)
>>> d3
{1: 4, 2: 5, 3: 6}
>>> d
{'man': 'huacong', 'woman': 'syj', 'is_couple': 1, 'have_child': 0}
>>> d4=dict(d)
>>> d4
{'man': 'huacong', 'woman': 'syj', 'is_couple': 1, 'have_child': 0}

```

图 3.6: dict 用法

`d.items()` 方法获取字典里的键值对的列表 (`dict_items`)。

`zip` 可以但不仅限于将用作键名的列表, 和用作键值的列表, 打包成键值对元组的列表 (可以是任意的列表)。

3.3.6 集合

集合用得不多, 但是可以看看图 3.7。

数学里的集合是无序的, 不重复的, Python 亦然。对于集合, Python 支持用操作符和方法来完成。现用一张表格来总结, 其中

$$A = \{1, 2, 3\}$$

$$B = \{1, 3, 4\}$$


```

>>> a,b = set([1,2,3]) ,set([1,3,4])
>>> a&b,a|b,a-b,a^b
({1, 3}, {1, 2, 3, 4}, {2}, {2, 4})
>>> a.discard(1)
>>> a
{2, 3}
>>> a.remove(1)
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
KeyError: 1
>>> a.add(1)
>>> a.update([1,2,3,4,5,6])
>>> a
{1, 2, 3, 4, 5, 6}
>>> b.issubset(a),b<=a
(True, True)
>>> a.issuperset(b),a>=b
(True, True)
>>> a.pop()
1
>>> a.clear()
>>> a
set()
>>> a&=b
>>> a
set()
>>> a|=b
>>> a
{1, 3, 4}
>>>

```

图 3.7: set 用法

remove 方法和 discard 方法，都可以去掉集合中的元素，区别在于当集合中没有指定元素的时候，前者抛出异常，后者什么都不执行。

clear 方法可以清除所有的元素。

3.4 流程控制

3.4.1 选择

```

if 情况1: # 情况不用加括号
    做一些事
elif 情况2: # 可选 else if 的意思
    pass # 啥都不做，相当于 java 和 c 中的;
elif 情况3:
    做另外的事
else: # 可选
    啥都不做

```

代码清单 if-elif-else

表 3.1: Set 用法

操作	结果	操作符	方法
并集	{1, 2, 3, 4}	a b	a.union(b)
交集	{1, 3}	a&b	a.intersection(b)
差集	{2}	a-b	a.difference(b)
相对差集	{2, 4}	a^b	a.symmetric_difference(b)
A 真包含于 B	False	a<b	a.issuperset(b)
让 set “A” 只保留 set “B” 中有的元素	None	a&=b	a.intersection_update(b)
让 set “A” 添加 set “B” 中有的元素	None	a =b	a.update(b)
让 set “A” 变成 AB 的相对差集	None	a^=b	a.symmetric_difference_update(b)
让 set “A” 变成 AB 的差集	None	a-=b	a.difference_update(b)

友情提醒

Python 中没有 switch-case 语句，因为 switch-case 和 if-elif-else 代码量差不多，功能也一致，the zen of Python 里有一条 There should be one– and preferably only one –obvious way to do it.

Python 条件，用 and,or,not 来连接，不用 &&,||,!。

Python 允许 2<money<=3 这样的写法。

is 判断是否是同一个对象（id(对象) 是否相等），== 判断值是否相等。

c/Java 中的 a?b:c 的条件表达式，在 Python 中写作 b if a else c。返回 b（如果满足条件 a 的话）否则返回 c。

3.4.2 循环

for

```
for 变量 in 可迭代的对象: #可以是列表，元组，字典，集合，range对象、生成器等
    做一些事
else: # 可选，当for循环中没有成功break时
    做别的事
```

代码清单 for-else

while

```
i=0
while 条件成立:
    i+=1 # 没有i++的说法
else:
    做别的事
```

代码清单 while-else

3.4.3 异常处理

```
try:
    raise Exception('some string')
except KeyError as e: # 捕捉到异常1并垂命名
    pass
except (NameError, TypeError): # 捕捉到2种异常，按相同方式处理
    pass
except:
    pass
else:
    pass
finally: # 无论如何都会进行，用于关闭数据库连接等。
    pass
```

代码清单 try-raise-except-finally

3.5 其它特性

嵌套。由于 Python 是动态类型，因此，你可以很容易地构建出多维列表等高级的数据结构。

关键字 in 可以检查对象是否在列表，元组，字符串，字节，字典的键名，集合中。

del 语句可以按照索引删除列表元素、按照键名删除字典元素。

如果想要模块的内容在这个模块里调用，但被导入到对应的模块时不调用，可以再前面加上 `if __name__ == '__main__':`

assert 用于断言。

* 可用于重复，比如 'python'*10。

+ 可用于字符串、元组、列表的拼接。

% 可用于字符串格式化和求模 (c、java、c++ 中是求余)。

Python 支持按位与、按位或、按位非、移位运算。

int, float, str, list, tuple, dict 等都可以用对应的类名进行转化。

yield 类似 return，不同点在于 yield 返回值后还会继续进行，使用了 yield 的函数被称为生成器，用 next 函数调用，得到下一个值。生成器的好处是只有在调用的时候才会生成相应的数据（调用到这个数据的时候才会生成这个数据，没有调用到时就没有这个数据），只记录数据的当前位置。

可以用列表/集合/字典/元组表达式配合条件表达式等完成列表/集合/字典/生成器的初始化。

```
a = [[1 if i==j else 0 for i in range(3)] for j in range(3)] # 三阶对角阵
b = {x**2 for x in range(-5,5)} # {0,1,4,9,16,25}
c = (x for x in range(3)) # 生成器
```

代码清单 list comprehension

在一些函数中的定义中，还可以看到，函数的参数还有 *args, **kwargs，分别用于多个位置参数，和多个关键字参数，实际上用到的数据结构为元组和字典。

在调用的时候也可以用 *[], **kwargs，不常用，在参数较多的时候用。

```
def a(*x):
    print(x)

def b(**y):
    print(y['a'],y)

def c(a,b,c,d):
    print(a,b,c,d)

def d(a,b,c=1,d=2,e=5,f=6):
    print(a,b,c,d,e,f)

a([1,2,3,4,5])# 调用的时候只有一个位置参数。
b(**{'a':1,'b':2,'c':3,'d':4})# 不加星相当于1个位置参数。
c(*[1,2,3,4])# 调用的时候, 相当于4个位置参数。
d(*[1,2,3],**{'d':3,'e':4,'f':5})# 调用的时候, 3个位置参数和3个关键字参数。
```

代码清单 args-kwargs

到现在 Python 的基本语法已经讲得差不多了, 还有文件读写和面向对象没讲, 留到需要用的时候再拓展。可以再看看 requests, 或者找一些标准库的模块, 是不是好懂很多 (当然有些函数不是用 Python 实现的, 所以你可能找不到 Python 代码)。

学完了这么多, 稍微放松一下。

```
import sys
寻找女朋友=lambda x:print('%d岁, 寻找女朋友ing...'%x)
结婚=lambda x:print('%d岁, 结婚啦,xswl'%x)
单身=lambda :print('emmm其实单身也挺好...')
等死=lambda:print('等死,人最终还是要死的, 也不知我死的时候是一个人还是两个人, 都有可能')

def 生活(结婚年龄):
    for 年龄 in range(5):
        print('%d岁, 没印象, 应该单身吧? '%年龄)
    for 年龄 in range(5,10):
        print('%d岁~%d岁, 有印象, 单身!'%(年龄,年龄+1))
    for 年龄 in range(10,20,2):
        print('%d岁~%d岁, 依然单身'%(年龄,年龄+2))
    while 40>年龄 >=18:
        try:
            寻找女朋友(年龄)
            还没找到女朋友 = 年龄<结婚年龄-3
            if 还没找到女朋友 and 年龄<30:
                continue
            elif not 还没找到女朋友:
                pass
            else:
                raise Exception('唉, 注孤生')
        except Exception as e:
            print(e)
        else:
            结婚(年龄+3)
            return
    finally:
        等死()
        年龄+=1
    单身()

if __name__=='__main__':
    assert len(sys.argv)==2,'输入结婚年龄哦'
    结婚年龄=int(sys.argv[1])
```

本章小结

本章介绍了 Python 的基本语法，内容较多，但较为枯燥，但是这些内容是后面内容的基础。下章开始介绍爬虫。

Chapter 4

爬虫基础

这什么爬虫别的语言都可以写，python 爬虫却那么火呢？

因为各种语言所代表的吉祥物里，只有蛇最能爬，也只能爬。

——土卫十六

这句话我是在开源中国社区^[1]看到的，幽默地解释了为什么 Python 适合写爬虫。通过这章的学习，希望大家能真正体会到 Python 写爬虫有多方便，并且，能自己动手写简单的爬虫。

首先，得来解释一下，Python 语言所代表的吉祥物。^[2]

不知道大家是否还记得 Python 的自拍图 2.1 吗？它像两条蛇。Python 的意译也是大蟒蛇。

可以说 Python 写爬虫确实很方便，但是，Python 在其它方面也不是一无是处的，比如在科学计算、机器学习等方面也是很火的。

为什么说绝大多数爬虫用 Python 写呢？我来分析一下原因。

- 1) 爬虫大概可以分为两类，一种是以获取数据为目的的，比如从政府网站获取各税务局的公告，一种是获取数据之后，还要对数据进行处理加工，比如分析 app 评论的情感倾向。前者，应尽可能方便地发送 HTTP 请求、解析返回的内容、存取数据，Python 可以做到；后者除了前面这些需求，还需要些自然语言处理、机器学习、科学计算方面的库，Python 也可以做到。
- 2) Python 成名早，听说 Nodejs（执行 js 代码比较方便），golang（并发方便，性能好）之类的写爬虫手感不比 Python 差，相关的库支持也很好，但它们出场晚，就没这么好的机会了。
- 3) Python 语法简单，在编写代码爬虫的过程中会需要反复修改代码（同一个网站不同页面，代码可能不同），因此，解释型语言比编译型语言方便很多。

^[1] 开源中国社区，https://www.oschina.net/question/2320879_2286597

^[2] 各种语言所代表的吉祥物，见http://www.sohu.com/a/121622929_455711。

4.1 爬虫流程

爬虫一般的流程可以分为：

1. 确定目标网站以及对应的网页
2. 发送请求
3. 解析响应内容并下载到本地或者进入数据库

当然这不是一成不变的，有时候，因为需求不一样，要存放到不同数据库。再比如有的时候需要发送好几次请求，才能确定目标网址。响应内容也不一样，有的是 json, 有的返回 html。有的网站反爬虫的措施不一样，有的可能需要让你的爬虫模拟登录状态的用户，甚至有的时候还要验证码识别……有的网站还要封你的 IP，你需要用代理 IP……需要很多各种各样的操作。

4.2 用到的知识

发送 HTTP 请求的时候，需要用到各种各样的 HTTP 协议方面的知识，比如 GET（常用于获取网络内容）、POST 方法（登录、发表内容等），还要会分析网络请求（header, cookie, 请求到哪个页面等）。解析页面的时候，要用到 HTML、JavaScript 的知识，也要用到 xpath、css 选择器、正则表达式，json 库，string 库和其它 Python 基础的语法。存储的时候，至少要会文件读写，还有至少一种数据库，SQL 比如 MySQL 等，NoSQL 比如 Mongoddb 和 Redis 等。如果你对其中一个不熟悉，可以去找找教程，但是不用学特别细。图像处理的库和验证码识别的库。

等等！为啥那么多的知识你都不讲？我怕是看了假书吧？

因为，讲太多容易忘记啊！我敢打赌，赌一毛，前面的内容，你已经忘记很多了。(好吧，别打我，我承认，是我讲得不好，所以你才忘了。)

本章小结

本章特别短，介绍了爬虫的流程和所需基本知识。下一章开始，我们用 requests 库开始写爬虫。

Chapter 5

项目一：——纪念你的《古剑奇谭三》游戏瞬间！盖楼晒图赢 GTX1080TI 显卡！

表 5.1: 工具说明

工具	用途	备注
火狐浏览器	查看代码	其它浏览器也行，但是可能没有火狐好用

不要相信天上会掉显卡，如果有，也是百度贴吧送的；不要相信你会中奖，哪怕你会写爬虫

——华聪

接下来，我们打算写一个爬虫，去爬取百度贴吧——古剑奇谭吧里面的信息（笔者看到了 Nvidia GTX 1080Ti 显卡，以后读研会用到深度学习，但是穷逼笔者买不起，尴尬，但是笔者还是有梦（野）想（心）的，买不起，去抢一个呗，而且重要的是，这么抢不犯法，嘻嘻。至于我怎么知道这个 GTX1080Ti 是 Nvidia 的，很简单，因为我事先看过了）。

友情提醒

先泼一盆冷水，这回显卡没抢到，模仿浏览器在百度贴吧里发帖子，确实不是很容易，所以，下面的规则之类的，可以不用仔细看。直接看下面的一部分就行。

这个爬虫游戏的具体规则是啥呢？详情见<https://tieba.baidu.com/p/5964052167>，不过这里，我还是要不厌其烦地敲敲黑板、划划重点，仔细研读一下游戏规则，免得到时因为没看清游戏规则，吃了哑巴亏。

《古剑奇谭三》晒图抢楼活动规则

1. 本次活动以“抢楼”的方式选择中奖玩家并且发放奖品。

2. 只要贴吧用户在本帖回复的楼层数符合获奖楼层的设置，就获得该楼层的奖品。
3. 不重复获奖原则，同一个贴吧 ID 至多只能获得 1 个奖品。获奖顺序由楼层数从小到大计算。
4. 每个百度贴吧帐号可以重复在晒图贴中回复。
5. 请勿连续回复超过三次（不包括三次），如果发现某个用户在某奖品楼层超过三层连续回复将取消该奖品的获奖资格，奖品顺延至下一个回复用户。
6. 本活动解释权归百度古剑奇谭吧吧务组所有。
7. 5 楼楼中楼里小吧主说，要回复古三的游戏截图才有效哦。
8. 活动时间截止时间：2018 年 12 月 3 日 24:00 之前（不包括 24:00）的最后一楼

这个爬虫怎么写呢？我们先分析一下需求。

我们要的奖品是 Nvidia GTX 1080TI 显卡在 21080 楼，截至笔者写作时间（11 月 30 日 11:49），已经盖了 1182 楼了，时间才花了 1 天不到（21 小时左右）1/4 时间。所以，这个进度明显不行啊 TAT。我们首要要做的就是盖楼。盖楼的过程中需要注意以下几点：

1. 时刻关注楼层信息，避免错过奖品。
2. 不重复获奖，如果我们不小心获得了别的奖，显卡就和这个号说 ByeBye 了。我们在其它开奖楼层的时候，不要刷太多，否则会影响主办方。
3. 回复截图才有效。因此，前期，只要不回复图片，就不会获得奖品了。后期，首先你得准备足够多的图片（至少 3-5 张吧），不重复。做为一个云玩家（说说，看视频）
4. 不要疯狂刷，多隔一点时间，给人一种你是打字的感觉。如果你发的太快，你的楼可能会被度娘“抽了”，尤其是快到开奖的时候，但是可以多开几个号刷。
5. 多开几个号刷，要注意开奖楼层到时，最好不要用异步^[1]的方法刷，因为异步无法保证连续 3 个或以内的楼层被你占据（占了 4 个机会就取消了，虽然从概率上来讲这个概率很小，但是也要控制一下）。
6. 登录才能发帖，但是看帖（我们看帖是为了获取楼层数）可以不登录。

5.1 获取总楼层数

什么楼决定什么奖，快到了，再全力发图。所以，我们很有必要做一个监视器，来获取总共的楼数，说白了，就是 `get` 方法获取网站源代码，然后，解析出对应的数字。监视嘛，当然越实时越好。所以，我们最好得对所有的代码进行性能方面的测试。

先确定要获取哪个页面的源代码。

注意，这里的图 5.1(a)的数据是总回复数，不是总楼层数，因此不准。(b)是准的回复。选中 1997 回复贴之后，右键查看选中部分代码（View Selected Source）。我们只要请求(b)对应的 url，并解析出(c)对应的代码，就可以获取楼层数。但是事后我看了，这个数字也不准，因为可能会有删掉

^[1]这里有 4 个概念需要搞清楚，同步异步阻塞非阻塞，见<https://www.zhihu.com/question/19732473/answer/14413599>



(a) 古剑奇谭吧首页



(b) 1 楼所在那一页上面或下面

```
<li class="l_reply_num" style="margin-left:8px" ><span class="red" style="margin-right:3px">1867</span>回复贴, 共<span class="red" style="margin-right:3px">64</span>页, 跳到 页 确定
```

(c) 选中 xxxx 回复贴之后, (火狐) 右键 View Selection Source

图 5.1: 楼层数

的楼层。所以, 最后, 我们还是要访问最后一个页面的最后一个楼层, 才能知道, 已经有了多少个楼了。可以自己试着找找在哪里可以找到这些信息, 用刚才说的技巧。不过这里也要说一下一个问题, 你会发现每次请求 (同步模式下) 楼层数和页面数, 并不总是增加的 (问了一些大佬, 也不是很清楚, 个人猜测, 应该和服务器的缓存有关, 毕竟你的爬虫不会被百度封, 又有那么多人用百度, 因此, 服务器方面的技术, 不会大差)。

这里给出我写的代码, 仅供参考。

```
#!/usr/bin/env python3
# -*- coding: utf-8 -*-
"""
Created on Sat Dec 1 13:54:52 2018

@author: hc
"""
import re, requests, random
import random

# 编译的工作可以留到循环外面进行, 避免重复计算
# 用来解析最后一页
last_page = re.compile('<a href="/p/5964052167/?pn=(\\d+)">尾页</a>', flags=re.S)
# 解析出所有包含楼层的信息
floor = re.compile('<span class="tail-info">(\\d+)楼</span>', flags=re.S)

def get_floor(url='https://tieba.baidu.com/p/5964052167'):
    max_floor = 1
    session = requests.session()
    while True:
        resp = session.get(url)
        # 返回页面源代码
        content = resp.text
        pn = re.search(last_page, content).group(1)
        # 访问最后一页
        resp = session.get(url + '?pn=' + pn)
        # 得到最后一个楼层信息。
        last_floor = re.findall(floor, resp.text)[-1]
        # 如果楼层增长很快, 避免更新过快, 来不及看。可将下面的输出注释
        print(last_floor)
```

```
        if int(last_floor) > max_floor:
            max_floor = int(last_floor)
            print('last_floor', last_floor)

if __name__ == '__main__':
    get_floor()
```

友情提醒

这里采用了同步的方法进行爬取，每次 get 有 0.7 秒左右的间隔，感觉实时性不够可以利用 gevent 库变成异步的，个人感觉这个实时性可以了

表 5.2: get 方法效率比较

用时 (秒) \ 方法 次数	requests.get	session.get (包括最前面一次 session = requests.session())
1	0.9074869155883789	0.9165563583374023
10	10.25405502319336	7.508088111877441

可以看出，第一次 requests.session 稍微花点时间，时间久了，肯定是 session.get 方法实时性更好。

re.search 函数会在字符串内查找模式匹配，只要找到第一个匹配然后返回，如果字符串没有匹配，则返回 None。re.match 函数比 re.search 函数要求严格。从首字母开始开始匹配，无法满足此处的需求。re.findall 返回的是所有满足条件的字符串的数据，和 re.finditer 返回的是所有满足条件的字符串的迭代器，效率也没有 search 好。

5.2 需要改进的地方

嗯？写爬虫很简单？你想多了！百度是最好爬的网站之一，因为年代久远，页面主体基本都是 HTML 页面直接加载的，很少有用 js 加载的，这儿，你用右键查看源代码和 F12 查看器 (inspector) 完全一致。而且百度因搜索引擎成名，本身有价值的数据并不多，没必要进行保护^[2]，因此，反爬虫的机制不强，可以说，如果仅仅是做个监视器，这个爬虫的技术是简单的。作为初学者，你可以点到为止，了解到这里就差不多了，本章的目的也仅在此。

但是，这个爬虫的提升空间是非常大的，这里还有很多事没有做，比如把我们的监视器用 gevent 等库改写成异步模式，来获得更好的实时性（毕竟抢显卡，价值不菲，因此人很多，刻不容缓）；再比如发包含图片帖，你首先要登录，然后文件上传。不得不说，百度在安全这方面做得还是可以的，登录不是光秃秃的，而是要 RSA 加密，验证码等技术，这些用 Selenium 这个爬虫框架可以较方便解决，selenium 可以用来模拟登录的请求，但 selenium 对文件上传支持得不好，性能也差，我就是卡在后者，如果不用 selenium，性能会好很多，但是需要分析请求和 js 代码，找出这些功能对应的请求以及请求的参数，以及 cookie 中有效的参数，写代码的时间和难度就会大大地增加，这里就不介绍了。再比如碰到动态加载的页面怎么爬等。

^[2]可能部分比较新的政府网站，就会有反爬虫的机制了，比如浙江政务服务网<http://www.zjzwfw.gov.cn>

友情提醒

由于 selenium 文件上传我没有实现，因此没留代码。另外我用 pillow 库（import PIL）写了一个打水印的代码（watermark.py）玩，但是需要 simkai.ttf, windows 里有。

本章小结

本章介绍了基本的爬虫，仅涉及到几个基本的内容，普通页面的抓取，正则表达式的简单运用。适合新手学习，但也提出了一些较难的问题，老手也可以有一定的思考，新手应先跳过。下一章，我们将学习简单的模拟登录，并获取登录后的信息，并提交一些信息。

Chapter 6

考前小作弊——写爬虫刷 acm 题

计算机的强大，在于它能把重复的任务进行优化，以非常快的速度完成。

——华聪

转眼又到期末了呢。对于大四的老人老华来说，大一时候，期末熬夜刷 ACM 题目的经历仍历历在目。一想到马上就要离开浙师大了，不禁又怀念起当年还是小鲜肉时候拼搏的那段时光呢（好吧，其实是当年万恶的老师要求要刷 100 道题才能平时满分）。说干就干，注册一个小号，装回嫩，emmm, 就叫 hc2000 好了,hc 变成 00 后啦！密码随便一点，就叫 1q2w3e 好了，刷题去！

可是这些题我都刷过，再刷一遍好像也没什么意义，不如 emmm 抄一遍吧，看着一道一道 ac，也蛮有成就感的呢。

打开以前的账号一看，哇，以前的我真努力（现在居然堕落成这样，汗！），刷了这么多题。这下可有的我好交了。

一道一道交可真够麻烦的，毕竟我可是刷了 250 多道题的男人。要不就写个爬虫自动提交吧！emmm 让我想想到底要实现什么功能呢？首先，要登录原有账号，查看正确提交的题目列表。然后，查看自己的代码。然后，登录另一个账号，提交对应的代码。



6.1 模拟登录

在介绍如何模拟登录前，我先不亲自讲登录是怎么一回事，我们通过登录过程中发出的请求来解释。

先安利一波抓包工具，常用的抓包工具/请求分析工具有

1. 浏览器自带的开发者工具（F12）中的网络。免费，写爬虫，基本够用，但是也许不一定好用。
2. burpsuite。新版收费，基于 java，跨平台，功能强大。笔者以前搞安全的时候也用到过，甚至还有一系列插件。
3. charles。收费，基于 java，跨平台，功能适中。

4. **Fiddler**。基于 .Net, 只能用于 Win 或者 Mac。

5. **wireshark**。功能强大, 面向数据帧, 但是门槛较高。

笔者这里选的是 charles^[1], 因为跨平台, 而且可以免费试用 30 天, 该有的功能全都有。建议去官网下载。正常情况下, Chrome DevTool 已经满足了日常 web 开发的需求, 但是有的特性: 编辑 request 的参数、重定向 request 请求的资源、编辑 response 的数据, Chrome DevTool 就不太好用了, 而且查看和调试移动端资源时候 Chrome 也并不好用;

送上 charles 教程一份<https://www.cnblogs.com/jiayuchn-test/p/8875105.html>, 请自行寻找其它教程。

如果你配置好浏览器和 charles 的代理^[2], 并且打开了开始录制按钮 (左上角红色圆形的按钮), 你再访问网站, 可以看到如图 6.1 所示的界面。左边是按照 structure (不同域名的请求被分开了) 或者 sequence (按照时间) 进行分类显示的结果。右边下面是响应, 上面是请求。

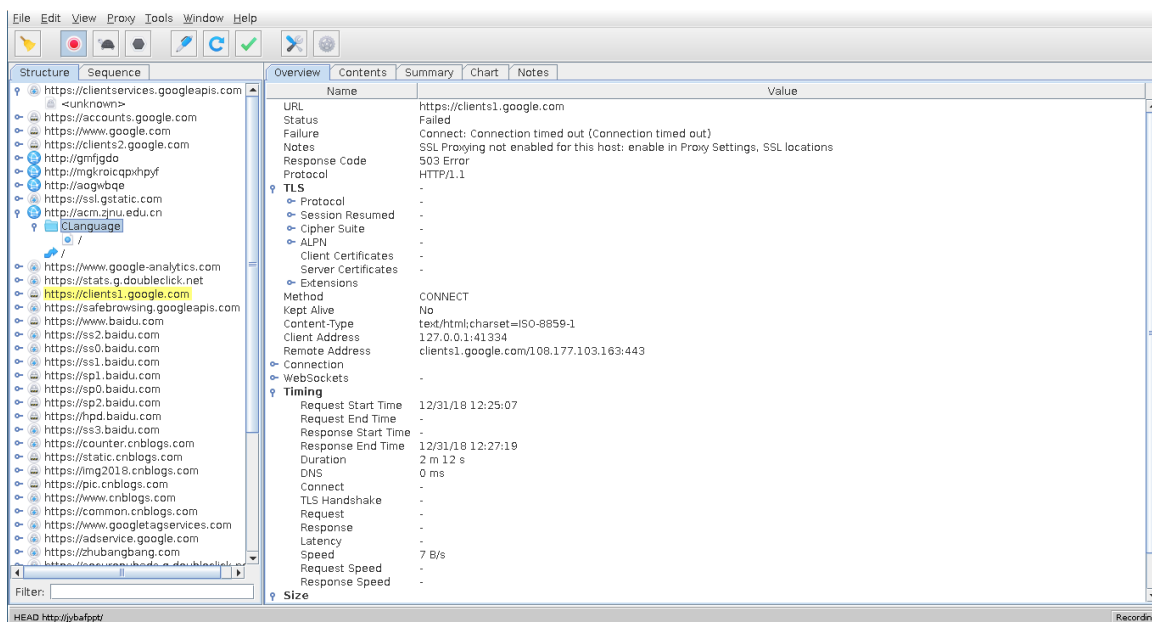


图 6.1: charles 界面

多访问几个网页, 你就晕了对吧? hhh 点击左上角的扫把 (clear the current session) 世界就清净了。

接下来, 我们就去用 charles 这个工具, 去看看, 登录具体是怎么样的!

在 acm 登录网站 (也就是主页) 输入账号密码钩上 remember me, 点击 login, 然后看下 charles 图 6.2, 然后你就可以在右边的 Overview (概观) 选项卡里看到请求的 URL 为 <http://acm.zjnu.edu.cn/CLanguage/login>。返回的状态码是 302。Method 是 POST, 也就是说, 我们发送了一个 POST 请求请求的主体部分 (也就是我们提交的东西) 可以在 Contents (内容) 里面查看到。

^[1]你可能会用到的小网站: https://blog.csdn.net/qz_25821067/article/details/79848589

^[2]所谓代理呢, 就是浏览器不直接访问网站, 而是访问一个指定的 IP 以及端口, 再由这个端口来帮助访问浏览器 (比如 charles 可以对发送的数据进行监视或者修改再发送), 因此, 浏览器和 charles 的代理设置 (proxy-proxy settings) 要一样, 设置代理请百度

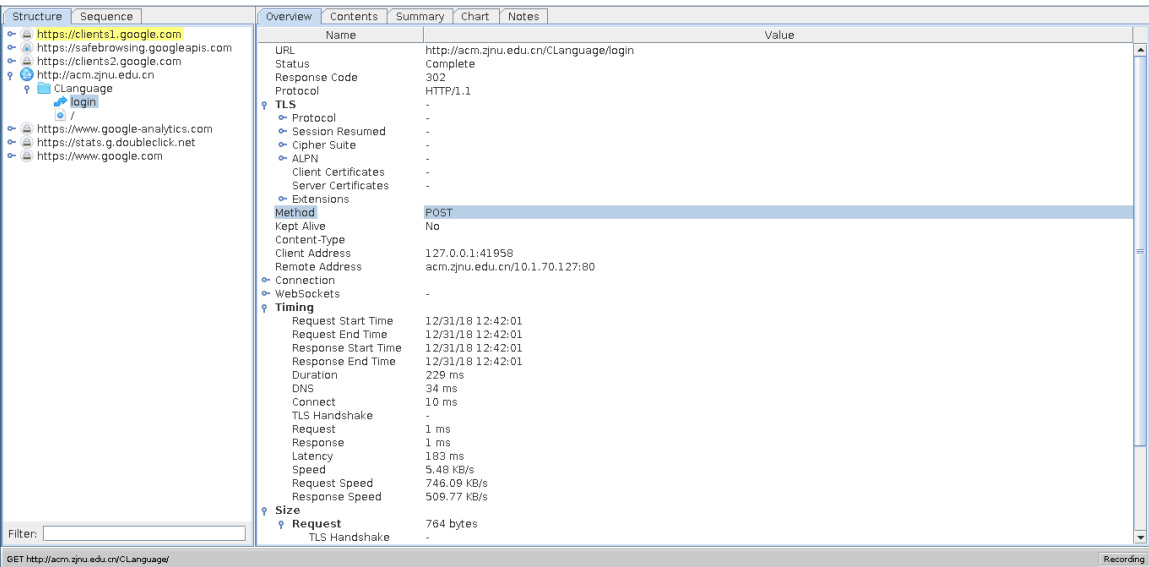


图 6.2: 登录




图 6.3: 表单数据

我们可以在图 6.3看到，我们提交的数据，都是明文^[3]（也就是没有被任何加密算法加密过）

这一部分 (图 6.4) 不是每个字段都需要关注。感兴趣的可以百度一下。但是这里有个 User-Agent 字段还是需要了解一下，表示你用的什么代理的工具（一般是浏览器，但是有的爬虫框架，可能会设置成自己）。有些后端会进行验证（比如一些新手，写爬虫，很可能比较懒，请求头里啥都不放，而正常的请求里，是有 User-Agent 的，那么，就可以进行判别，是否是爬虫）。一个较简单的做法，就是打开开发者工具（或者抓包工具），找一个请求，把 headers 复制下来。写代码的时候用。

另外，图 6.4里面有个 cookie 字段，表示请求时的 cookie，用来跟踪会话，标志是否是同一个用户，是否登录过，是否要保存登录状态等。在 Cookies 选项卡 (图 6.5) 里，可以看到具体的 cookie。对应的，下面有个 set cookie，表示响应里设置的 cookie。一些难模拟登录的（比如有验证码），可以手动登录，手动获取 cookie，设置 cookie。

然后，text 部分 (图 6.6) 就是你真正提交的东西。曾经见过某度把真正提交的内容改了一个格式，然后用框架里的方法或者函数，就会报错，因为格式不一样。这里可以看到，提交的时候，像 “/” 这类奇怪的字符会被 URL 编码（大部分是 “%” 加上对应的 ASCII 码的 16 进制形式）。

好了，我们可以知道模拟登录大概的流程了。梳理如下：

^[3]这样有个坏处，比如我和你在同一个局域网里，我可以通过抓包的方法，获取你的密码，所以，你可以去试试一些正规的网站，密码都是加密过的

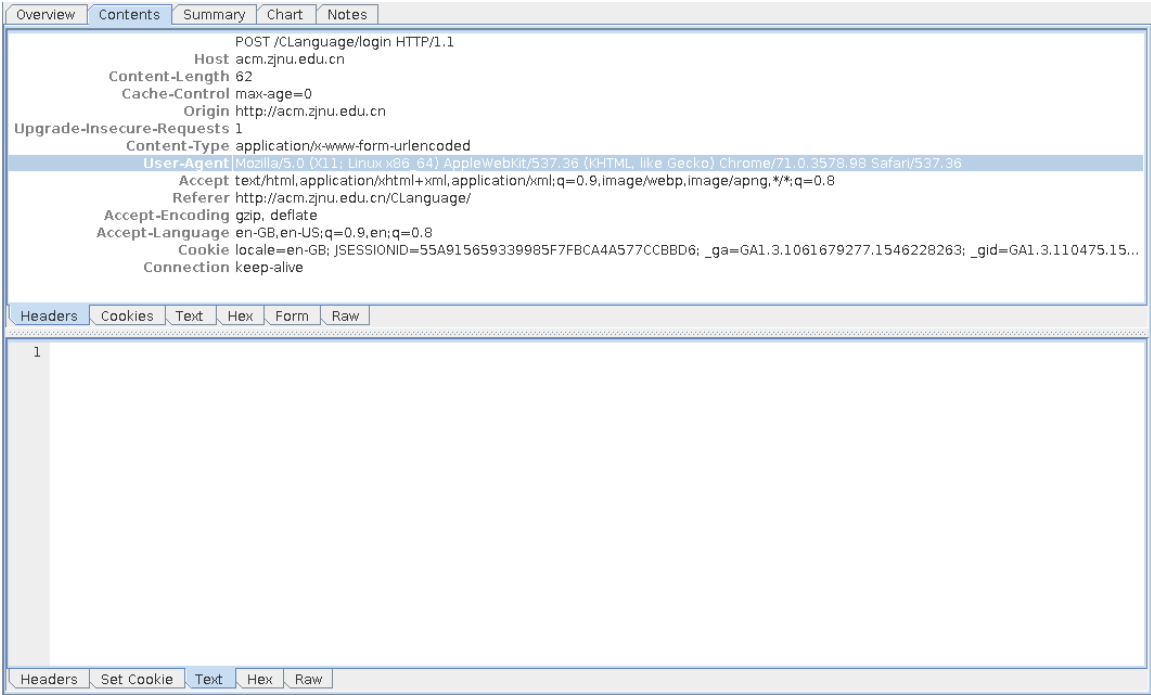


图 6.4: 请求头

1. 先用 charles 等工具，找到登录请求的那个页面（login），不是登录按钮所在的那个页面（index），把对应的参数提交上去。
2. 获取返回的 cookie，并在接下来每次请求时候都带上它。因为这是判断你是否登录过的重要凭证之一。

友情提醒

第一步，也可以通过查看源代码的方式分析，但是，这样工作量太大，十分不推荐，因为简单

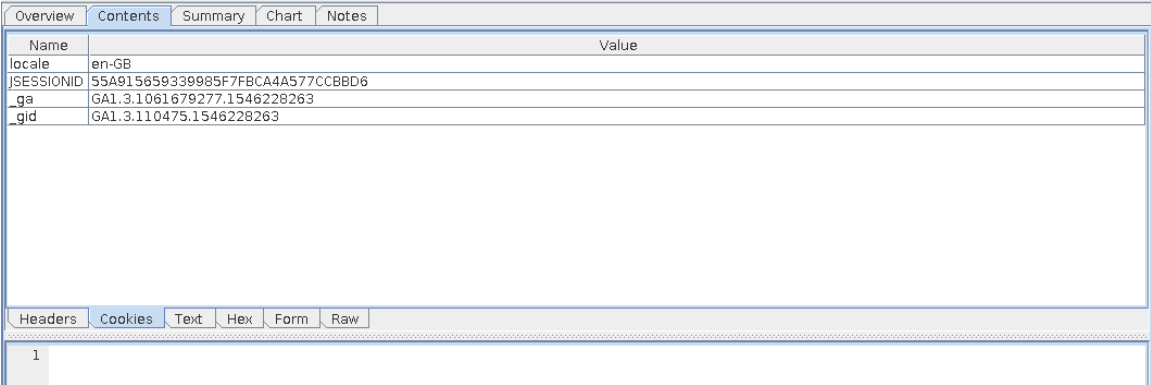


图 6.5: 请求 cookie

点的，是在 form 的 action 里，难点的是通过 js 提交的

写段代码试试！

```
import requests

def login(username, password, remember_me=True, url="http://acm.zjnu.edu.cn/CLanguage/
    login"):
    # 获取一个session,会自动帮你处理好cookie,类似下面这样
    # cookies = dict(cookies_are='working')
    # requests.get(url, cookies=cookies)
    # 一些难模拟登录的（比如有验证码），可以手动登录，手动获取cookie,设置cookie
    #
    session = requests.session()
    # 以POST方法提交数据登录,以及设置User-Agent, 这个网站没有检验，随便写不写
    resp = session.post(url, data={
        'user_id1': username,
        'password1': password,
        'rememberMe': True,
        'url': '/'
    }, headers={"User-Agent": "balabala"})


    # 获取返回的内容
    content = resp.text
    # 如果登录成功，就可以看到自己的用户名
    assert content.find(username) > 0
    print('登录成功')

    # 返回session,毕竟后面还要用到
    return session

if __name__ == '__main__':
    session = login('201539100122', '1q2w3e')
```

6.2 查看做过的题目

嗯，接下来，可以看看做过哪些题目啦。

在浏览器中登录后，按 F12 打开开发者工具。左上角找到箭头并点击。选中那个 ID 左边那栏带红钩的单元格，然后下面就自动跳到对应的源代码（如图 6.7所示）了。

简单分析一下代码，我们可以发现，AC（Accepted）的题目，都有一个 class="ac" 的 tr，其下的第二个 td 是题的 ID，第三个 td 下面的 a 标签里有一个链接。可以看到，题目显示在这个网页里。当然，我们不用查看题目，只要提交问题就够了，但是我们可以肯定的是，一定会用到这个 ID。

因此，我们要把 class="ac" 的 tr 给获取下来，再获取其第 2 个子 td。这里可以用正则表达式，但是比较麻烦（可以自己试试）。这里用 xpath 比较方便（比 css 选择器快），可以调用 xpath 的库有 2 个 beautiful soup4 和 lxml，其中 beautiful soup4 主要是用于 css 选择器的，xpath 部分是支持用 lxml 解析的，但是 api 比 lxml 简洁一点，而且涉及较少的 xpath 语法，lxml 涉及一些 xpath 语法。为了简单起见，我们先选择前者——bs4。

友情提醒

当然也可以像上章那样，选中一部分，然后右键，查看选中部分源代码，你可以看看哪个方便好用。这里应该差不多，因为网页比较简单，直接加载的，没有利用 ajax 请求，有些是利用 ajax 请求的，就不一样了，右键可能查看不到源代码。不同浏览器可能功能不一样，但是查看器是基本上都有的，

话不多说，上代码！（上一个函数 login 省略了。）

```
def search_questions(session):
    resp = session.get('http://acm.zjnu.edu.cn/CLanguage/problemlist')
    soup = bs4.BeautifulSoup(resp.text, 'lxml')
    id_list = []

    # 有个下划线, 返回所有的 class="ac" 的 tr
    for tr in soup.find_all(class_='ac'):
        # 返回 Tag 不是字符串 <class 'bs4.element.Tag'>
        # print(type(tr))

        # 返回的是第 2 个子结点的文本值
        id = tr.contents[1].text
        id_list.append(id)
    return id_list

if __name__ == '__main__':
    session = login('201539100122', '1q2w3e')
    id_list = search_questions(session)
    print(id_list)
```

6.3 获取代码

接下来可以获取代码了，在这一关要注意点什么呢？

1. 代码提交后的状态（是否 ac）
2. 代码的语言 (c, c++, java, python?)
3. 代码的格式是否会影响判别 (python)

为了简化，我们就只提交 1 次正确的即可，然后，不考虑用 Python、c、c++ 提交的（c 和 c++ 的可能由于编译器版本的关系，很早提交的可能现在并不能提交），只考虑用 java 提交的内容。

在 http://acm.zjnu.edu.cn/CLanguage/status?problem_id=&user_id=201539100122&score=100 这个页面我们可以看到所有做对的题目。

先上一段测试用的代码

```
def get_code_test(session):
    resp = session.get('http://acm.zjnu.edu.cn/CLanguage/showsource?solution_id=445870')
    soup = bs4.BeautifulSoup(resp.text, 'lxml')
    print(soup.find('code'))
```

然后我们惊奇地发现，图 6.8 输出是这个样子的，中间有很多 <>！

这些是个啥玩意儿？其实它们是'&','<','>'。好好的标点不写，为啥要写成这样呢？这是为了防止跨站脚本攻击（xss）。感兴趣的可以百度一下。

所以，我们需要再给它转义一下。

作业

布置一个小作业叭，把我所有的 java 提交成功的代码的链接和 runid 爬下来。URL: http://acm.zjnu.edu.cn/CLanguage/status?problem_id=&user_id=201539100122&language=3&score=100(只有没思路的时候再参考我的代码，至于不会写，可以百度)

答案:

```
def get_JAVAcodE_list(session):
    # language=3表示JAVA语言, score=100表示所有回答中100分的题目, 即ac的题目
    # 这些可以通过手动操作之后, 抓包获得
    url = 'http://acm.zjnu.edu.cn/CLanguage/status?problem_id=&user_id=201539100122&language=3&score=100'

    resp = session.get(url)
    soup = bs4.BeautifulSoup(resp.text, 'lxml')
    questions = []
    for tr in soup.find_all('tr', attrs={"align": "center", "bgcolor": None}):
        # 输出进行测试, 如果不加"bgcolor":None, 会匹配到另外2个tr
        # print(tr)
        runid = tr.contents[0].text
        # 所谓文本值, 就是把标签去掉, 因此在只有一个子结点的情况下, 不用再获取子结点
        problemid = tr.contents[2].text
        # print(runid, problemid)
        questions.append({
            "runid": runid,
            "problemid": problemid,
        })

    return questions
```

点击语言里的那个超链接http://acm.zjnu.edu.cn/CLanguage/showsource?solution_id=350943, 你可以看到自己写的代码。这里有个叫 solution_id 的参数, 观察一下就可以发现, 就是刚才那个 runid。

获取代码可以在刚刚那个 test图 6.8的基础上进行修改, 将转义过的字符串进行替换。

```
def get_JAVACODE(session, runid):
    resp = session.get('http://acm.zjnu.edu.cn/CLanguage/showsource?solution_id=%s'%runid)
    soup = bs4.BeautifulSoup(resp.text, 'lxml')
    return soup.find('code').text.replace('&', '&')\
        .replace('&lt;', '<')\
        .replace('&gt;', '>')

if __name__ == '__main__':
    session = login('201539100122', '1q2w3e')
    id_list = search_questions(session)
    # print(id_list)
    # get_code_test(session)
    questions = get_JAVAcodE_list(session)
    for question in questions:
        runid = question['runid']
        problem = question['problemid']
        code = get_JAVACODE(session, runid)
        print(code)
```

小诀窍

如果想只输出一次（因为输出多了就慢嘛～），又用不到 `return` 语句（不在函数内部），可以试试 `assert 0` 的方式终止（0 转换成的 `bool` 值为 `False`），比 `sys.exit` 方法快一点，还不用导入模块，但是可以被 `try-except` 捕获

6.4 提交代码

找到正确的入口，试着手动提交，然后先看下网页，再观察 `charles`，发现如图 6.9……

系统错误了，可能它们今天要训练？系统的锅，我不背哈哈。

算了，要做一个负责任的男人，自己挖好的坑，就算自己跳进去也要填满。再试试，这回果然可以提交了，原来刚才只是一个小意外。抓包后的结果，如图 6.10所示。3 个参数，在 `overview` 里可以看到 `Method` 为 `POST`，`URL` 为 <http://acm.zjnu.edu.cn/CLanguage/problems/1413/submit>

OK，这里还有一些小问题，比如提交太快，它不给过，所以要 `time.sleep(10)` 让它停一会，通过集合或者列表，让它不重复提交。

如图 6.11所示，总算可以畅快地“抄”题了，每次 10 秒左右，但是不用手动地提交了！

本章小结

本章介绍了一个生动的例子——提交 `acm` 题目，并通过这个例子，简单地介绍了抓包工具 `charles` 的使用，以及 `python` 库 `beautiful soup4` 的使用

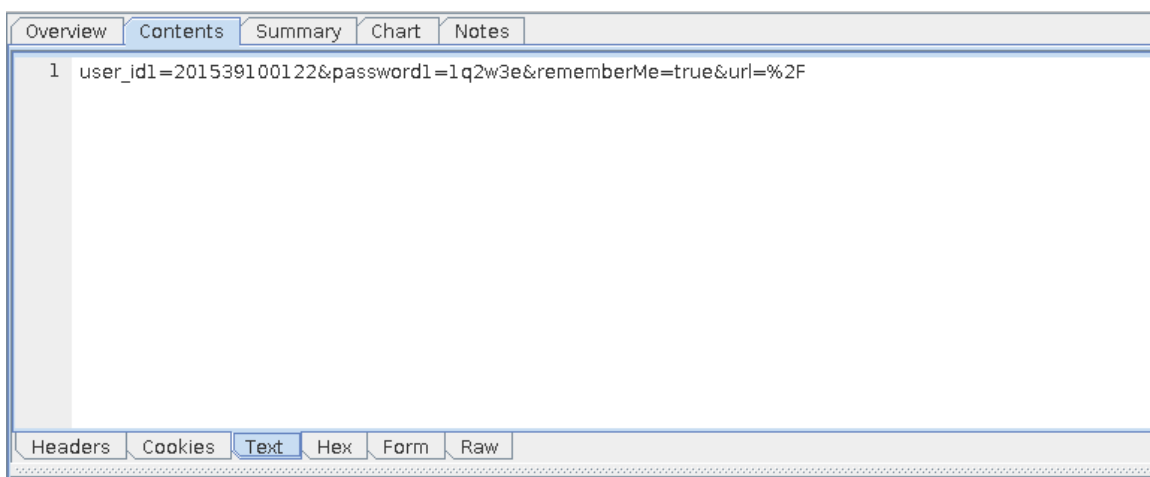


图 6.6: text

```
▶ <tr class="ac">...</tr>
▼ <tr class="ac">
  <td class="status"></td>
  <td align="center">1002</td>
  ▶ <td>...</td>
  ▶ <td align="center">...</td>
  <td align="center">39%</td>
  <td align="center">2018-12-30</td>
</tr>
▶ <tr class="ac">...</tr>
▶ <tr class="ac">...</tr>
```

图 6.7: 源代码

```

#include<stdio.h>;
#include<string.h>;
using namespace std;
#define max(a,b) a>b?a:b
#define min(a,b) a<b?a:b

int main(){
    int n,a[100],left[100],right[100];
    int cnt[100];
    while(scanf("%d",&n)!=EOF){
        memset(left,0,sizeof(left));
        memset(right,0,sizeof(right));
        for(int i=0;i<n;i++){
            scanf("%d",&a[i]);
        }
        for(int i=0;i<n;i++){ // i left
            int tmp=0;
            for(int j=0;j<i;j++){
                if(a[j]<a[i]){
                    tmp=max(tmp,left[j]);
                }
            }
            left[i]=tmp+1;
        }
        for(int i=n-1;i>=0;i--){
            int tmp=0;
            for(int j=n-1;j>i;j--){
                if(a[j]<a[i]){
                    tmp=max(tmp,right[j]);
                }
            }
            right[i]=tmp+1;
        }
        int minn=200;
        for(int i=0;i<n;i++){
            cnt[i]=n-(left[i]+right[i])+1;
            minn=min(minn,cnt[i]);
        }
    }
}

```

图 6.8: 代码




图 6.9: 系统错误




图 6.10: 抓包结果

Run ID	User	Problem	Result	Score	Memory	Time	Language	Code Length	Submit Time
561473	hc2000	1413	Accepted	100	OK	203MS	Java	1451 B	2019-01-01 10:22:18
561472	hc2000	1307	Accepted	100	OK	703MS	Java	1143 B	2019-01-01 10:22:07
561471	hc2000	1179	Accepted	100	OK	281MS	Java	674 B	2019-01-01 10:21:57
561470	hc2000	1121	Accepted	100	OK	203MS	Java	344 B	2019-01-01 10:21:46
561469	hc2000	1408	Accepted	100	OK	375MS	Java	989 B	2019-01-01 10:21:35
561468	hc2000	1400	Accepted	100	OK	1484MS	Java	771 B	2019-01-01 10:21:24
561467	hc2000	1466	Accepted	100	OK	203MS	Java	405 B	2019-01-01 10:21:13
561466	hc2000	1405	Accepted	100	OK	187MS	Java	1185 B	2019-01-01 10:21:02

图 6.11: 提交结果